### Obtenção de Dados

EST0133 - Introdução à Modelagem de Big Data

Marcus Nunes https://introbigdata.org/ https://marcusnunes.me/


Universidade Federal do Rio Grande do Norte



### Introdução


- · Nem sempre é fácil conseguir dados para análise
- Como é possível extrair diversas informações a partir de análises, muitos vezes o acesso a dados é cobrado
- · Veremos aqui como encontrar e baixar dados gratuitos da internet
- Além disso, vamos aplicar técnicas para o processamento destes dados visando sua análise posterior

### Introdução





### **Dados Brutos**



### **Dados Brutos**

- · Dados brutos são dados sem tratamento algum
- · São os dados originais, vindos diretamente da fonte
- Através dos dados brutos conseguimos as tabelas que serão utilizadas em nossas análises

### **Dados Brutos**

- Há diversas maneiras de dados brutos serem obtidos a partir da internet
- · As maneiras principais são
  - 1. Download via sites de divulgação
  - 2. Web scraping
  - 3. Solicitação direta

### Download de Dados Brutos

- Instituto Brasileiro de Geografia e Estatística (IBGE) https://downloads.ibge.gov.br/
- · Banco Central do Brasil https://www3.bcb.gov.br/sgspub/
- · Portal Brasileiro de Dados Abertos http://dados.gov.br
- · Portal da Transparência http://www.transparencia.gov.br/
- UFRN http://dados.ufrn.br/

### Download de Dados Brutos

- Brasil.io https://brasil.io/
- Kaggle https://www.kaggle.com/datasets
- UCI Machine Learning Repository https://archive.ics.uci.edu/ml/
- The home of the U.S. Government's open data https://www.data.gov/

### Download de Dados Brutos

- · O R possui vários conjuntos de dados já pré-instalados para análise
- O comando
  - > data()

lista todos os conjuntos de dados disponíveis nos pacotes carregados na memória do R

- · O comando
  - > data(package = .packages(all.available = TRUE))

lista todos os conjuntos de dados disponíveis em todos os pacotes do R disponíveis na sua instalação local

- 1. Vá ao Kaggle e baixe o conjunto de dados Pokemon with stats
- 2. Carregue este conjunto de dados no R
- 3. Conte as occorrências dos tipos de habilidades principais entre os pokémons (Type.1) e as classifique em ordem decrescente
- 4. Crie um boxplot com o poder de ataque (Attack) dos Pokemons e ordene o eixo x de acordo com a ordem decrescente das medianas para cada nível da variável Type. 1
- 5. Identifique, através de um gráfico e uma regressão linear, se existe relação entre o valor de ataque e defesa dos pokémons (Attack e Defense)

## Web Scraping

### Web scraping

- · Termo que significa vasculhar a internet através de dados
- A ideia é coletar e organizar automaticamente os dados que estão espalhados em um ou mais sites
- Logicamente, apenas dados abertos ao público podem ser coletados desta maneira

### Web scraping


- · O R possui pacotes que realizam este tipo de trabalho
- Existem desde pacotes bastante específicos, como o twitteR, até pacotes com usos mais gerais, como o rvest e XML
- $\cdot$  O desempenho do R é bastante satisfatório para este tipo de situação

### Web scraping

- Abra o arquivo 01\_Obtencao\_De\_Dados\_Codigos.R para ver uma aplicação de web scraping utilizando o R
- Veremos como obter os dados de todos os pilotos da história da Fórmula 1 a partir da Wikipedia

Processamento dos Dados

### Processamento dos Dados




### Processamento dos Dados

- · Muitas vezes os dados brutos não estão prontos para análise
- Cada caso é um caso; técnicas que servem para preparar um conjunto de dados muito provavelmente não vão servir para preparar outro conjunto
- Vamos ver algumas técnicas aplicadas nos dados dos pilotos de Fórmula 1

### Análise dos Dados

### Análise dos Dados




### Análise dos Dados

- Fica imensamente mais fácil proceder com a análise dos dados após eles terem sido previamente processados
- Perceba que o banco de dados criado com os dados dos pilotos de Fórmula 1, após ser processado, é muito mais fácil de analisar do que o conjunto original
- Ele está pronto para ser trabalhado por um programa como R, SAS ou até mesmo Excel

- 1. Classifique os pilotos Fórmula 1 em ordem decrescente de número de campeonatos, informando seu nome e país de origem
- 2. Encontre os 10 países com mais títulos na modalidade
- 3. Faça um gráfico do número de vitórias dos pilotos versus número de pole positions
- Altere a cor dos pontos do gráfico anterior, identificando-os de acordo com o número de campeonatos vencidos por cada um

# Reportar a Análise

### Reportar a Análise



### Reportar a Análise

- · As conclusões tiradas na análise são reportadas neste passo
- Tente mantê-las interessantes e simples, além de concisas e completas
- Uma tendência atual é usar dados para contar uma história; tente se valer de uma abordagem assim para manter seu interlocutor interessado

- 1. Encontre e baixe no R a página da Wikipedia PT com a lista dos municípios brasileiros por população
- 2. Encontre e baixe no R a página da Wikipedia PT com a lista dos municípios brasileiros por área
- Combine os resultados dos itens 1 e 2 em um data frame só, utilizando a função left\_join do pacote dplyr
- 4. Limpe o data frame resultante do passo acima deixando-o apenas com as colunas municipio, estado, area e populacao, nesta ordem, sem acentos ou letras maiúsculas

- 5. Crie o gráfico de dispersão de população versus área. O que é possível perceber? Altere os eixos, um de cada vez e simultaneamente, para a escala logarítmica na base 10 e veja se a visualização melhora.
- 6. Encontre as cinco cidades com maior e menor população do Brasil
- 7. Encontre as cinco cidades com maior e menor densidade populacional do Brasil
- 8. Encontre as cinco cidades com maior e menor população do Rio Grande do Norte
- 9. Encontre as cinco cidades com maior e menor densidade populacional do Rio Grande do Norte

### Obtenção de Dados

EST0133 - Introdução à Modelagem de Big Data

Marcus Nunes https://introbigdata.org/ https://marcusnunes.me/

Universidade Federal do Rio Grande do Norte