EST0133 - Projeto I

Marcus Nunes

10 de Fevereiro de 2021

Instruções

- A data limite de entrega é 22/02/2021, às 23:59, via SIGAA
- O R é o único software permitido para coleta, limpeza e análise dos dados
- Se preferir fazer o trabalho em R Markdown, utilize o arquivo `modelo.Rmd` para isso
- Renomeie-o para `NomeSobrenome.Rmd`, em que `Nome` é o seu primeiro nome e `Sobrenome` é um de seus sobrenomes
- Se preferir realizar o trabalho em outro formato que não seja R Markdown, os códigos utilizados e as respostas para as perguntas devem ser fornecidas em dois arquivos identificados como `NomeSobrenome.R` e `NomeSobrenome.pdf`
- Envie conjuntamente seus arquivos `NomeSobrenome.Rmd` (ou `NomeSobrenome.R`) e `NomeSobrenome.pdf` para avaliação em um arquivo chamado `NomeSobrenome.zip`
- Respostas em arquivos que não estejam nos formatos Rmd (ou R) e pdf não serão consideradas
- Identifique corretamente os eixos dos gráficos produzidos
- Respostas numeradas incorretamente não serão corrigidas

Parte I: Clusterização

O objetivo da primeira análise é identificar padrões em um conjunto de canções do serviço de streaming Spotify. O arquivo `spotify.csv` possui informacões a respeito de 3.000 canções retiradas do Spotify. As colunas do conjunto de dados são

- `track_id`: identificador único da faixa
- `popularity`: indicador de quão popular a faixa é, variando de 0 a 100
- `acousticness`: medida de 0 a 1 que indica o quão confiante o sistema está de que é uma faixa acústica, sendo que 1 representa alta confiança na acusticidade
- `danceability`: índice que mistura ritmo, batida e regularidade, indo de 0 a 1
- `duration_ms`: duração da faixa em milissegundos
- `energy`: medida de 0 a 1 que indica a intensidade da faixa em termos de velocidade, altura e barulho
- `instrumentalness`: variando de 0 a 1, indica a quantidade de palavras em uma faixa; rap tende a 0, música instrumental tende a 1
- `liveness`: indicador usado para determinar se a canção foi gravada ao vivo; valores próximos de 0 indicam estúdio, valores próximos a 1 indicam gravação ao vivo
- `mode`: família da faixa, indicando se os acordes são maiores ou menores
- `speechiness`: medida de 0 a 1 sobre a quantidade de palavras faladas na faixa; 0 a 0.33 indica faixas sem falas; 0.33 a 0.66 indica que a faixa contém música e letra; valores acima de 0.66 indica faixas compostas quase inteiramente por palavras faladas
- `tempo`: valor médio de batidas por minuto (bpm) da faixa
- `valence`: felicidade da faixa, variando entre 0 (músicas tristes, depressivas, raivosas) a 1 (músicas alegres, eufóricas)

Questão 1

(*10 pontos*) Leia o conjunto de dados dentro do R em um objeto chamado `spotify` e verifique suas variáveis através dos comando `head` e `summary`. Existem uma ou mais variáveis desse conjunto de dados que deveriam ficar fora da análise? Qual(is) e por quê? Retire-a(s) do conjunto de dados antes de prosseguir com a sua análise.

```
library(tidyverse)
theme_set(theme_bw())
library(ggfortify)
library(GGally)

spotify <- read_csv("dados/spotify.csv")

head(spotify)
```

```
## # A tibble: 6 x 12
##   track_id               popularity acousticness danceability duration_ms energy
##   <chr>                       <dbl>        <dbl>        <dbl>       <dbl>  <dbl>
## 1 duNRajiQO6hoqJbwORzh6q         20       0.821         0.684      139604 0.487
## 2 T2vrFw2HjJe6t8wc0EnSbV         35       0.73          0.451      159440 0.339
## 3 MT7qAQ25taWCIbSpsKGwsy          9       0.909         0.69        89195 0.607
## 4 OoYmLhIa7GVJ6T935Pab6g         12       0.741         0.461       72960 0.669
## 5 EJxDLVOpeKOwJSpeF1CcAt         56       0.0233        0.635      275586 0.588
## 6 7wkyWhInDPPhk5NHDw2fLy         34       0.982         0.316      163573 0.0417
## # ... with 6 more variables: instrumentalness <dbl>, liveness <dbl>,
## #   mode <chr>, speechiness <dbl>, tempo <dbl>, valence <dbl>
```

```
summary(spotify)
```

```
##    track_id           popularity     acousticness        danceability
```

```
##  Length:3000        Min.   : 0.00   Min.   :0.0000055   Min.   :0.0613
##  Class :character   1st Qu.:21.00   1st Qu.:0.2255000   1st Qu.:0.3648
##  Mode  :character   Median :33.00   Median :0.7995000   Median :0.4955
##                     Mean   :36.41   Mean   :0.6251525   Mean   :0.4721
##                     3rd Qu.:55.00   3rd Qu.:0.9300000   3rd Qu.:0.5930
##                     Max.   :84.00   Max.   :0.9960000   Max.   :0.8670
##   duration_ms          energy         instrumentalness       liveness
##  Min.   :  30200   Min.   :0.000589   Min.   :0.0000000   Min.   :0.0251
##  1st Qu.: 172632   1st Qu.:0.200000   1st Qu.:0.0000000   1st Qu.:0.1030
##  Median : 223574   Median :0.578500   Median :0.0000154   Median :0.1875
##  Mean   : 260587   Mean   :0.518138   Mean   :0.2145716   Mean   :0.3747
##  3rd Qu.: 293840   3rd Qu.:0.808000   3rd Qu.:0.3062500   3rd Qu.:0.7090
##  Max.   :3920687   Max.   :0.995000   Max.   :0.9880000   Max.   :0.9900
##      mode            speechiness          tempo           valence
##  Length:3000        Min.   :0.02280   Min.   : 32.45   Min.   :0.0237
##  Class :character   1st Qu.:0.03860   1st Qu.: 83.04   1st Qu.:0.1698
##  Mode  :character   Median :0.05275   Median :102.75   Median :0.3625
##                     Mean   :0.33801   Mean   :107.55   Mean   :0.3824
##                     3rd Qu.:0.90400   3rd Qu.:128.81   3rd Qu.:0.5623
##                     Max.   :0.96500   Max.   :219.33   Max.   :0.9800
```

```r
spotify <-
  spotify %>%
  select(-track_id)
```

A variavel `track_id` foi retirada porque não adiciona informação na analise, já que é única para cada faixa.

Questão 2

(*10 pontos*) Faça a análise exploratória do conjunto de dados, verificando as relações entre as variáveis e a sua distribuição geral. Aplique as transformações necessárias nele de modo a deixá-lo pronto para análise. Justifique as suas decisões para cada variável transformada.

```r
ggpairs(spotify,
        lower = list(continuous = wrap("points", alpha = 0.1)))
```

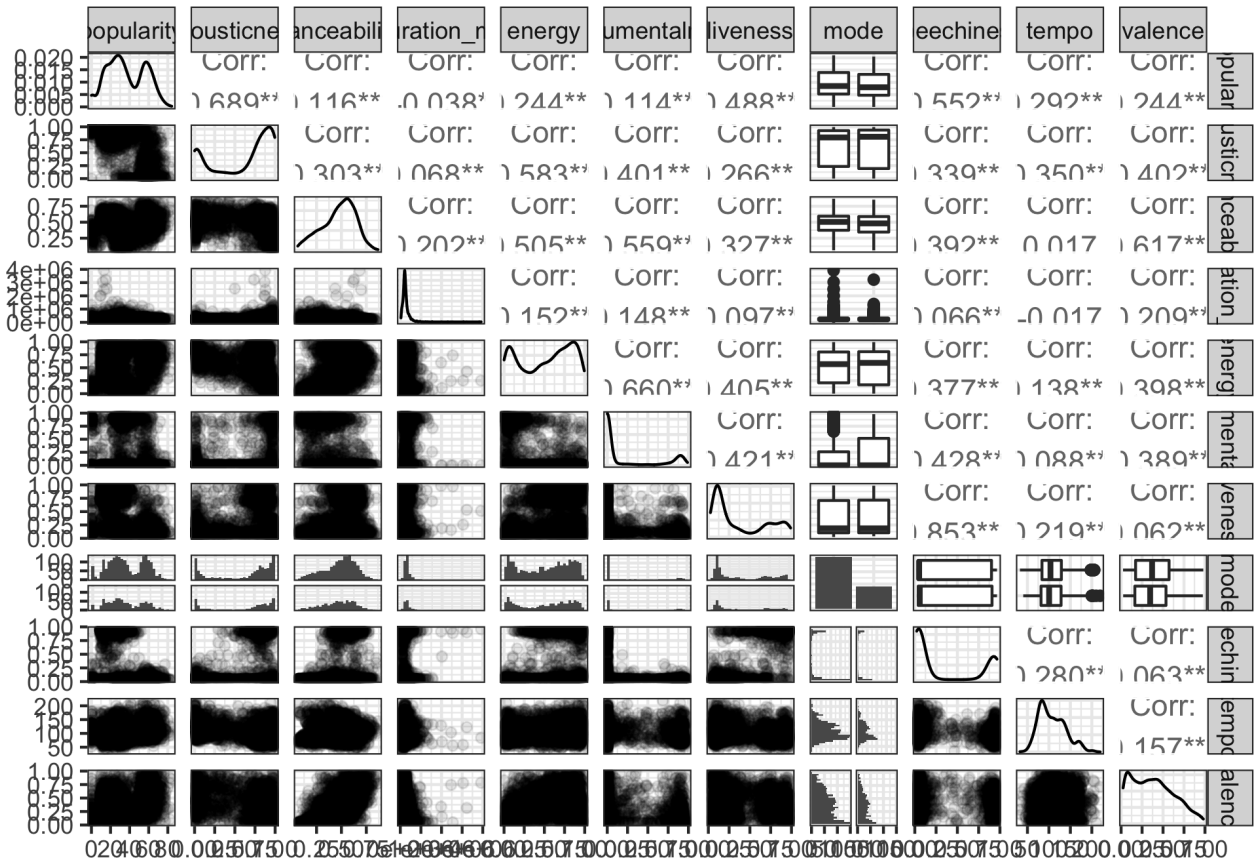


```r
spotify <-
  spotify %>%
  mutate(duration_ms = log(duration_ms), # assimetrica a direita
         instrumentalness = log(instrumentalness + 1), # assimetrica a direita
         liveness = log(liveness), # assimetrica a direita
         mode = ifelse(mode == "Major", 1, 0), # categorica
         tempo = log(tempo), # assimetrica a direita
         valence = log(valence + 1)) # assimetrica a direita

ggpairs(spotify,
        lower = list(continuous = wrap("points", alpha = 0.1)))
```

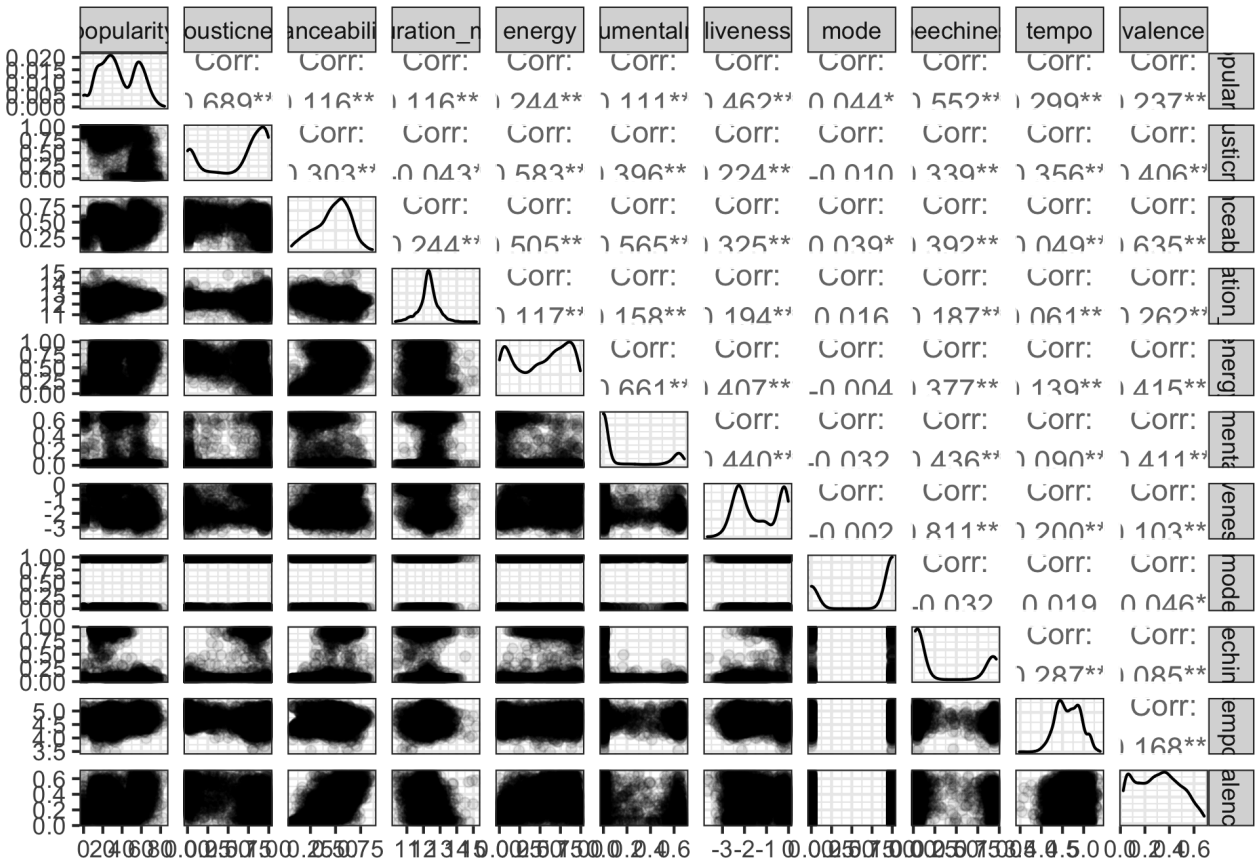

Algumas das variáveis apresentam simetria, o que é bom para nossas análises.

Por apresentarem assimetria à direita, as variáveis `duration_ms`, `instrumentalness`, `liveness`, `tempo` e `valence` foram transformadas utilizando logaritmo. Para que os logaritmos pudesse ser calculados, foi adicionado o valor 1 àquelas variáveis que possuíam observações iguais a zero.

A variável `mode` foi transformada de categórica para numérica convertendo os valores `Major` para 1 e `Minor` para 0.

Questão 3

(*10 pontos*) Crie a PCA para esse conjunto de dados, interpretando o resultado obtido com a PCA. Essa interpretação deve ser numérica e visual.

```
spotify_pca <- prcomp(spotify, center = TRUE, scale. = TRUE)

summary(spotify_pca)
```

```
## Importance of components:
##                          PC1    PC2     PC3     PC4     PC5     PC6     PC7
## Standard deviation     1.8505 1.6784 1.02473 1.00119 0.89172 0.81488 0.60481
## Proportion of Variance 0.3113 0.2561 0.09546 0.09113 0.07229 0.06037 0.03325
## Cumulative Proportion  0.3113 0.5674 0.66287 0.75399 0.82628 0.88665 0.91990
##                           PC8     PC9    PC10    PC11
## Standard deviation     0.5677 0.51322 0.43766 0.32230
## Proportion of Variance 0.0293 0.02394 0.01741 0.00944
## Cumulative Proportion  0.9492 0.97314 0.99056 1.00000
```

```
autoplot(spotify_pca,
         data = spotify,
         loadings = TRUE,
         loadings.label = TRUE) +
  theme_bw()
```

```
## Warning: `select_()` was deprecated in dplyr 0.7.0.
## Please use `select()` instead.
```

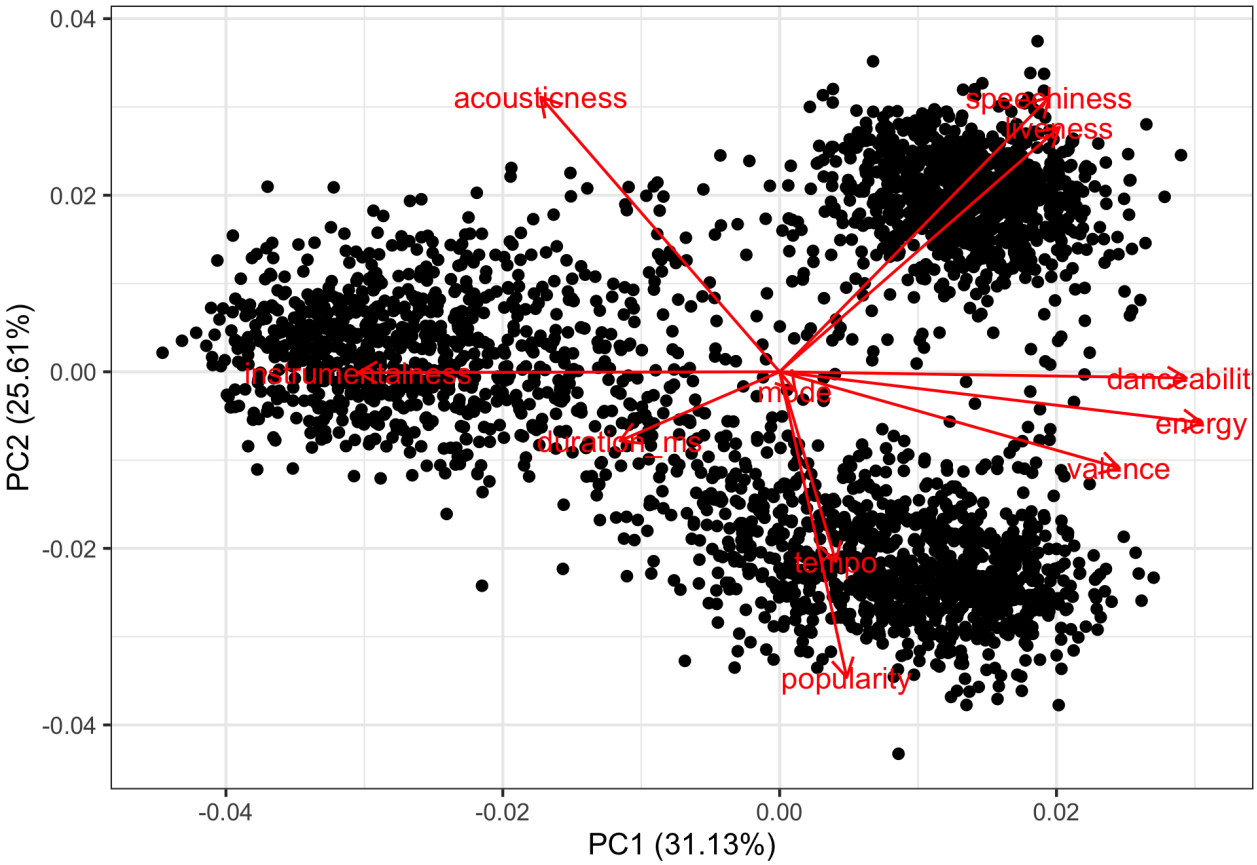

Após a transformação nos dados, encontramos uma PCA que concentra 56,74% da variabilidade dos dados nas duas primeiras componentes principais. São necessárias pelo menos as cinco primeiras componentes principais para que mais de 80% da variância seja explicada.

Ao fazer o gráfico da PCA, é possível encontrar três clusters de dados. Outras informações se destacam, como a oposição entre `acousticness` e as três variáveis `mode`, `tempo` e `popularity`. Além disso, `danceability`, `energy` e `valence` apontam simultaneamente para o mesmo lado, enquanto `instrumentalness` é diametralmente oposta a elas. Por fim, `speachiness` e `liveness` antagonizam `duration_ms`.

Questão 4

(*10 pontos*) As canções do conjunto de dados foram obtidas a partir de um determinado número de gêneros musicais. Utilize o k-means para encontrar o número de clusters correto para esse problema, com três critérios diferentes. Qual é a sua conclusão em relação ao número ideal de clusters?

```
library(factoextra)
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

```r
library(NbClust)

spotify_cs <- as.data.frame(scale(spotify))

kmeans2 <- function(x, k) {
  list(cluster = kmeans(x, k, iter.max = 20))
}

fviz_nbclust(spotify_cs, kmeans, method = "wss")
```

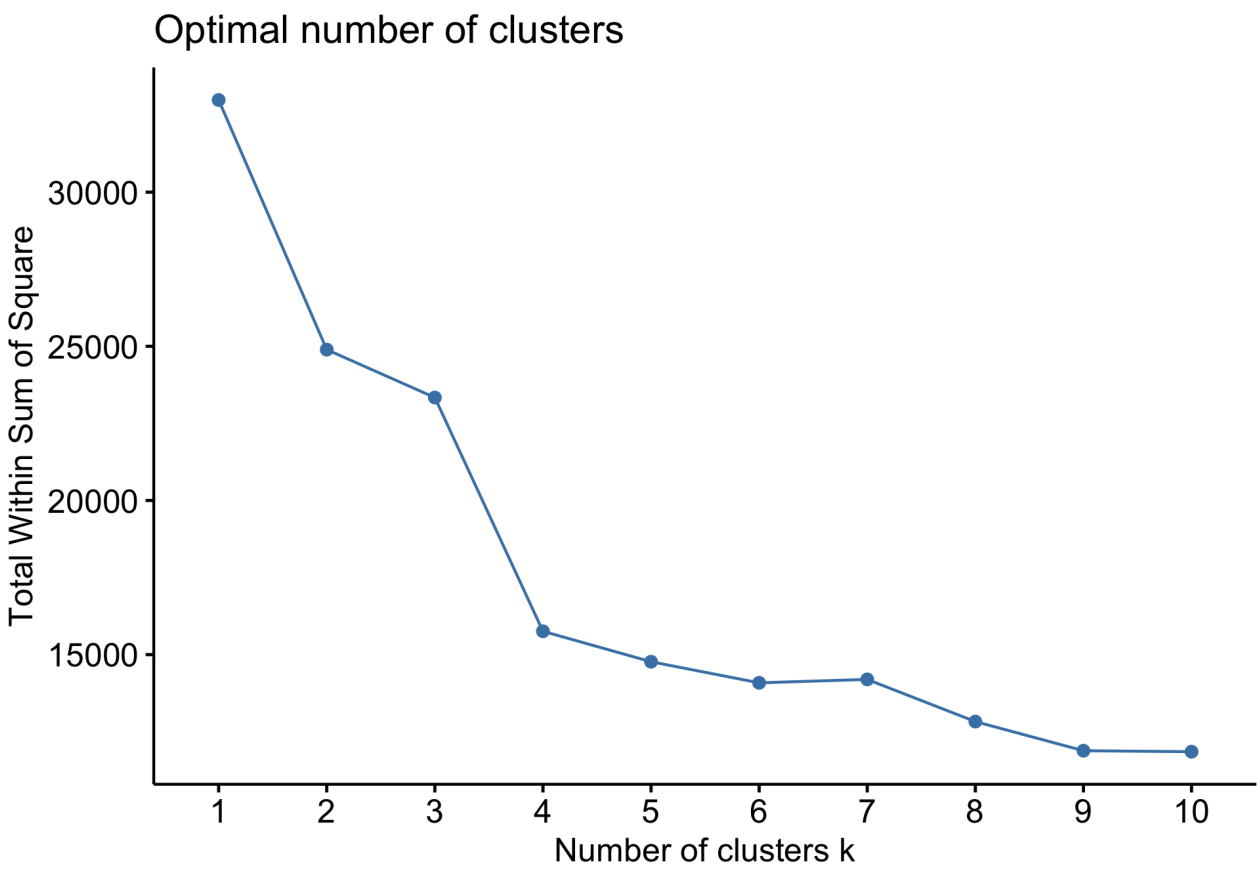


```r
fviz_nbclust(spotify_cs, kmeans, method = "silhouette")
```

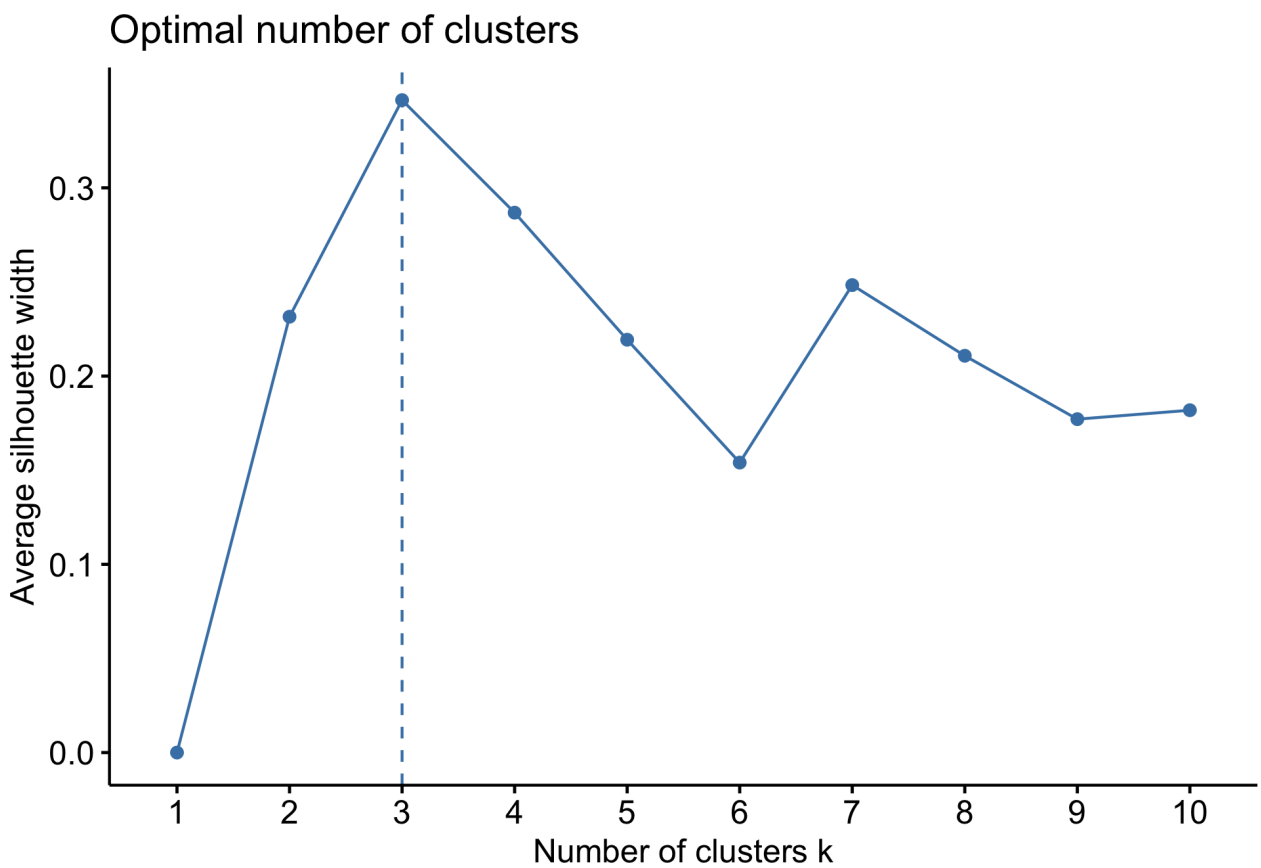


```
fviz_nbclust(spotify_cs, kmeans2, method = "gap_stat", nboot = 50)
```

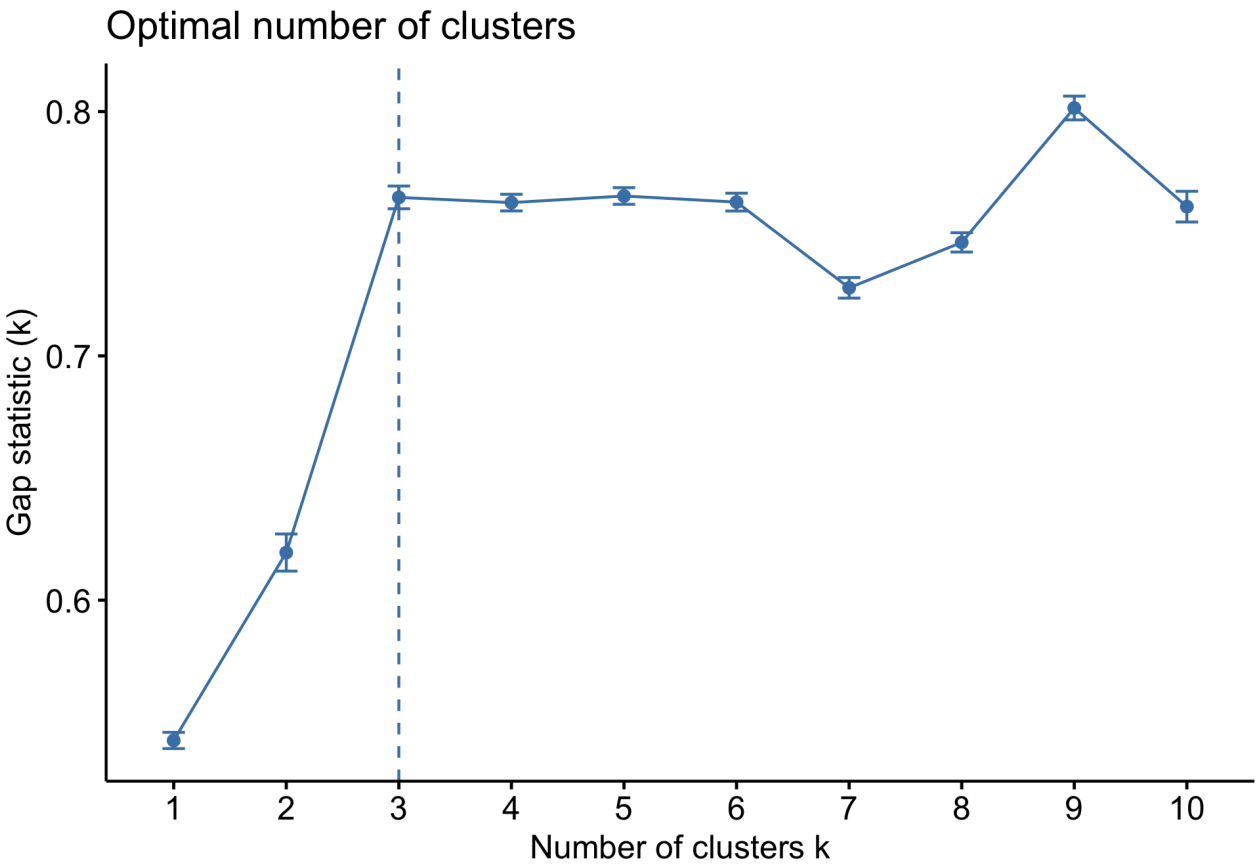

Dois dos três métodos utilizados sugerem três clusters para os dados. A excessão é o método do cotovelo, que nos indica quatro clusters. Como a PCA feita na questão 3 já nos sugeria três clusters, essa é a opção que utilizaremos nesse problema.

Questão 5

(*10 pontos*) Combine os resultados das questões 3 e 4, isto é, visualize o resultado da PCA colorindo os pontos de acordo com os resultados da clusterização. Qual é a sua decisão final a respeito do número correto de clusters para esse problema?

```
set.seed(10022020)

clusterizacao <- kmeans(spotify_cs, 3)

spotify_cs <- cbind(as.data.frame(spotify_cs),
                    cluster = as.character(clusterizacao$cluster))

autoplot(spotify_pca,
         data = spotify_cs,
         colour = "cluster",
         loadings = TRUE,
         loadings.label = TRUE) +
  theme_bw()
```

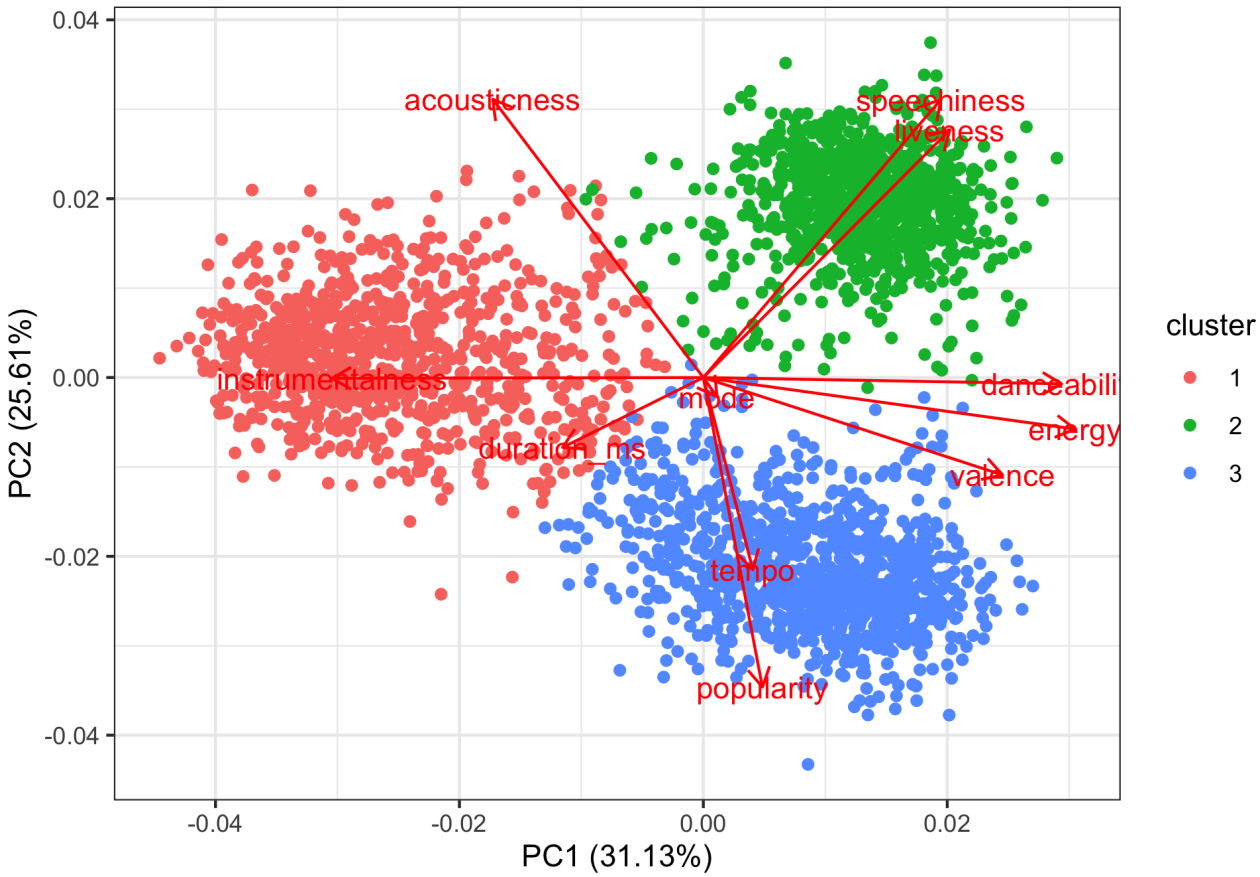

Três clusters parecem ser a melhor solução para esse problema. Além dos dois métodos numéricos que a sugerem, o gráfico acima parece funcionar muito bem com três grupos, com uma boa separação entre eles.

Questão 6

(*15 pontos*) Coloque as informações sobre a clusterização no conjunto de dados original, sem as transformações. Calcule a média, por grupo, das variáveis `popularity`, `instrumentalness` e `speechiness`. Através do resultado obtido, identifique qual o gênero de cada cluster, dentre as opções

- Música Clássica
- Música Infantil
- Rap
- Rock
- Shows de Comédia
- Trilha Sonora

Não é necessário utilizar todos os gêneros musicais. Alguns podem sobrar (ou não). Justifique a sua resposta.

```
spotify <- cbind(spotify,
                 cluster = clusterizacao$cluster)

spotify %>%
  group_by(cluster) %>%
  summarise_all(mean) %>%
  select(popularity, instrumentalness, speechiness)
```

```
## # A tibble: 3 x 3
##   popularity instrumentalness speechiness
```

```
##        <dbl>            <dbl>       <dbl>
## 1       29.7           0.457       0.0475
## 2       31.1           0.482       0.0509
## 3       39.2           0.0187      0.468
```

O cluster 1 possui `speechiness` alta, igual a 0.874. Além disso, sua `instrumentalness` é baixa. Essas duas características sugerem que esse cluster pertence à categoria Shows de Comédia.

O cluster 2 possui a maior `instrumentalness`, além de uma popularidade abaixo de 30. Juntando isso à sua baixa speechiness, esse cluster pertence à categoria Música Clássica.

Por fim, o cluster 3 possui `instrumentalness` em um valor intermediário entre Música Clássica e Shows de Comédia. O mesmo vale para sua `speechiness`. Sua popularidade é a maior de todas, o que indica ser da categoria Rock.

Parte II: Webscraping

A página *List of countries by GDP (PPP) per capita* da Wikipedia - https://en.wikipedia.org/wiki/List_of_countries_by_GDP_(PPP)_per_capita - exibe a lista de países de acordo com a Paridade do Poder de Compra (PPC em potuguês, PPP em inglês). Ela serve para comparar o poder aquisitivo entre os habitantes dos países, levando em conta o custo de vida local. Ou seja, em vez de apenas comparar o PIB per capita entre os países, a PPC leva em conta tanto as diferenças entre os rendimentos das pessoas como também as diferenças no custo de vida.

Questão 7

(*15 pontos*) Há três tabelas para o PPP na página da Wikipedia. Utilize webscraping para criar uma tabela com três colunas: `pais`, `ppp_fmi` e `ppp_wb`, com o nome dos países, PPP de acordo com o FMI e PPP de acordo com o Banco Mundial, respectivamente. Exclua da tabela os países que não possuem PPPs para o ano mais recente ou para as duas fontes de dados.

```
library(rvest)
```

```
## Loading required package: xml2

##
## Attaching package: 'rvest'

## The following object is masked from 'package:purrr':
##
##     pluck

## The following object is masked from 'package:readr':
##
##     guess_encoding
```

```
library(tidyverse)
theme_set(theme_bw())

url <- "https://en.wikipedia.org/wiki/List_of_countries_by_GDP_(PPP)_per_capita"

ppp <-
  read_html(url) %>%
  html_table(fill = TRUE)

fmi <-
  ppp[[3]] %>%
  select(pais = "Country/Territory", ppp_fmi = "Int$") %>%
  mutate(ppp_fmi = str_replace_all(ppp_fmi, ",", "")) %>%
  mutate(ppp_fmi = as.numeric(ppp_fmi))

wb <-
  ppp[[4]] %>%
  select(pais = "Country/Territory", ppp_wb = "Int$") %>%
  filter(!grepl("\\(", pais)) %>%
  mutate(ppp_wb = str_replace_all(ppp_wb, ",", "")) %>%
  mutate(ppp_wb = as.numeric(ppp_wb))

ppp <- left_join(fmi, wb) %>%
  na.omit()
```

```
## Joining, by = "pais"
```

Questão 8

(*05 pontos*) Como as estimativas de PPP são feitas por órgãos independentes, seus resultados podem variar. Quais são os países com as cinco maiores diferenças entre as estimativas, em valores absolutos? E em valores percentuais absolutos, tomando os valores do Banco Mundial como base de comparação?

```
ppp %>%
  mutate(diferenca_abs = abs(ppp_fmi - ppp_wb)) %>%
  arrange(desc(diferenca_abs)) %>%
  head(n = 5)
```

```
##                   pais ppp_fmi ppp_wb diferenca_abs
## 1                Macau   58931 129451         70520
## 2 United Arab Emirates   58466  70089         11623
## 3                Aruba   27169  38442         11273
## 4                Libya    4746  15846         11100
## 5               Kuwait   41735  52060         10325
```

```
ppp %>%
  mutate(diferenca_perc_abs = abs(ppp_fmi - ppp_wb)/ppp_wb*100) %>%
  arrange(desc(diferenca_perc_abs)) %>%
  head(n = 5)
```

```
##      pais ppp_fmi ppp_wb diferenca_perc_abs
## 1   Libya    4746  15846           70.04922
## 2   Macau   58931 129451           54.47621
## 3   Haiti    1728   3034           43.04548
## 4   Aruba   27169  38442           29.32470
## 5 Vietnam   10755   8397           28.08146
```

Questão 9

(*05 pontos*) Crie um gráfico de dispersão relacionando `ppp_wb` (eixo y) com `ppp_fmi` (eixo x). O que é possível perceber no resultado?

```
ggplot(ppp, aes(x = ppp_fmi, y = ppp_wb)) +
  geom_point() +
  labs(x = "PPP FMI", y = "PPP World Bank") +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed")
```

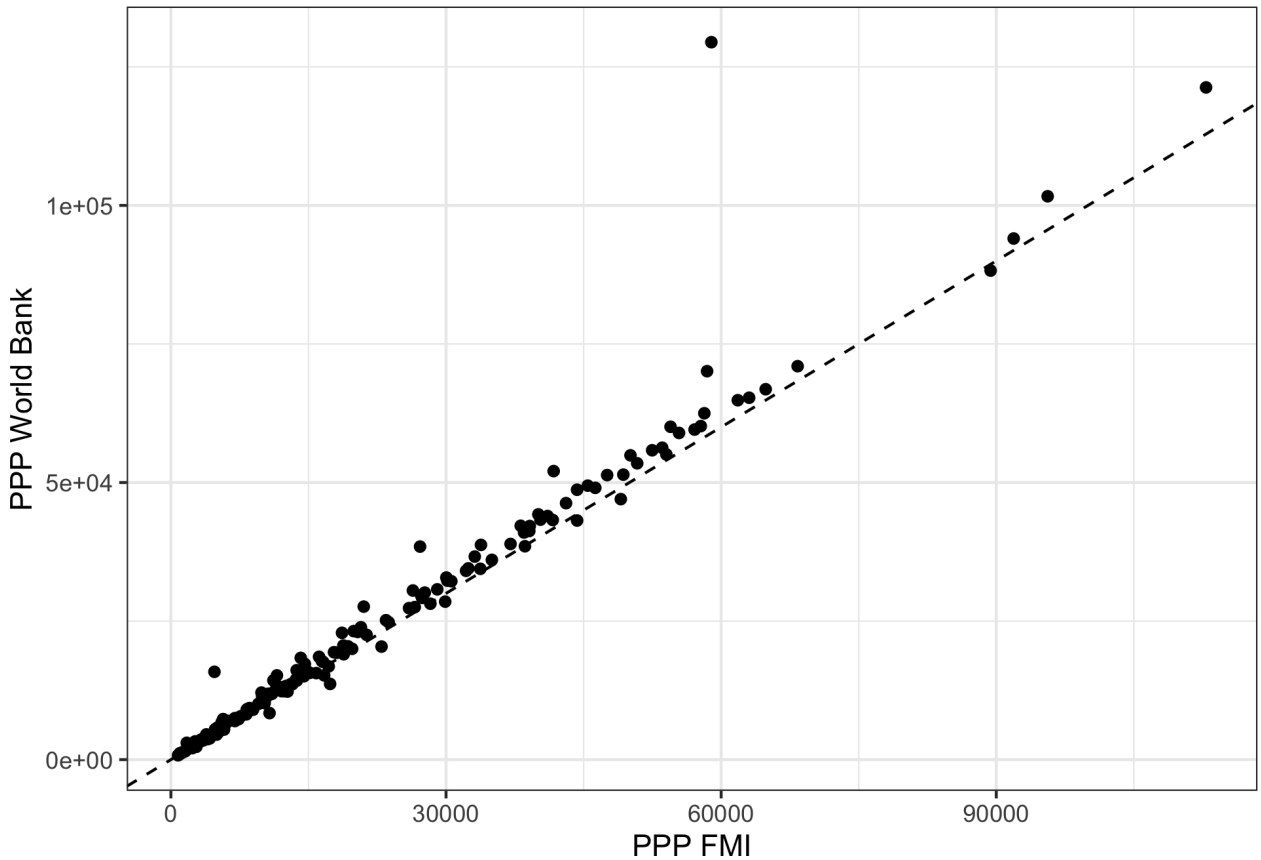

Embora haja uma forte concordância entre os PPP estimados pelo World Bank e pelo FMI, pois os pontos parecem estar bastante próximos da reta de referência, há casos que possuem estimativas muito diferentes, dependentes do órgão que as fez.

Questão 10

(*10 pontos*) Ajuste um modelo de regressão linear aos dados do gráfico da questão anterior. Na sua opinião, esse modelo está bem ajustado? Quais são os problemas em utilizar o modelo de regressão linear nesses dados?

```
library(ggfortify)

ajuste <- lm(ppp_wb ~ ppp_fmi,
             data = ppp)

summary(ajuste)
```

```
##
## Call:
## lm(formula = ppp_wb ~ ppp_fmi, data = ppp)
##
## Residuals:
##    Min     1Q Median     3Q    Max
##  -8795   -803   -290     90  65481
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -19.57477  540.93273  -0.036    0.971
```

```
## ppp_fmi       1.08584    0.01858  58.445   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5231 on 185 degrees of freedom
## Multiple R-squared:  0.9486, Adjusted R-squared:  0.9483
## F-statistic:  3416 on 1 and 185 DF,  p-value: < 2.2e-16
```

```
autoplot(ajuste)
```

```
## Warning: `arrange_()` was deprecated in dplyr 0.7.0.
## Please use `arrange()` instead.
## See vignette('programming') for more help
```

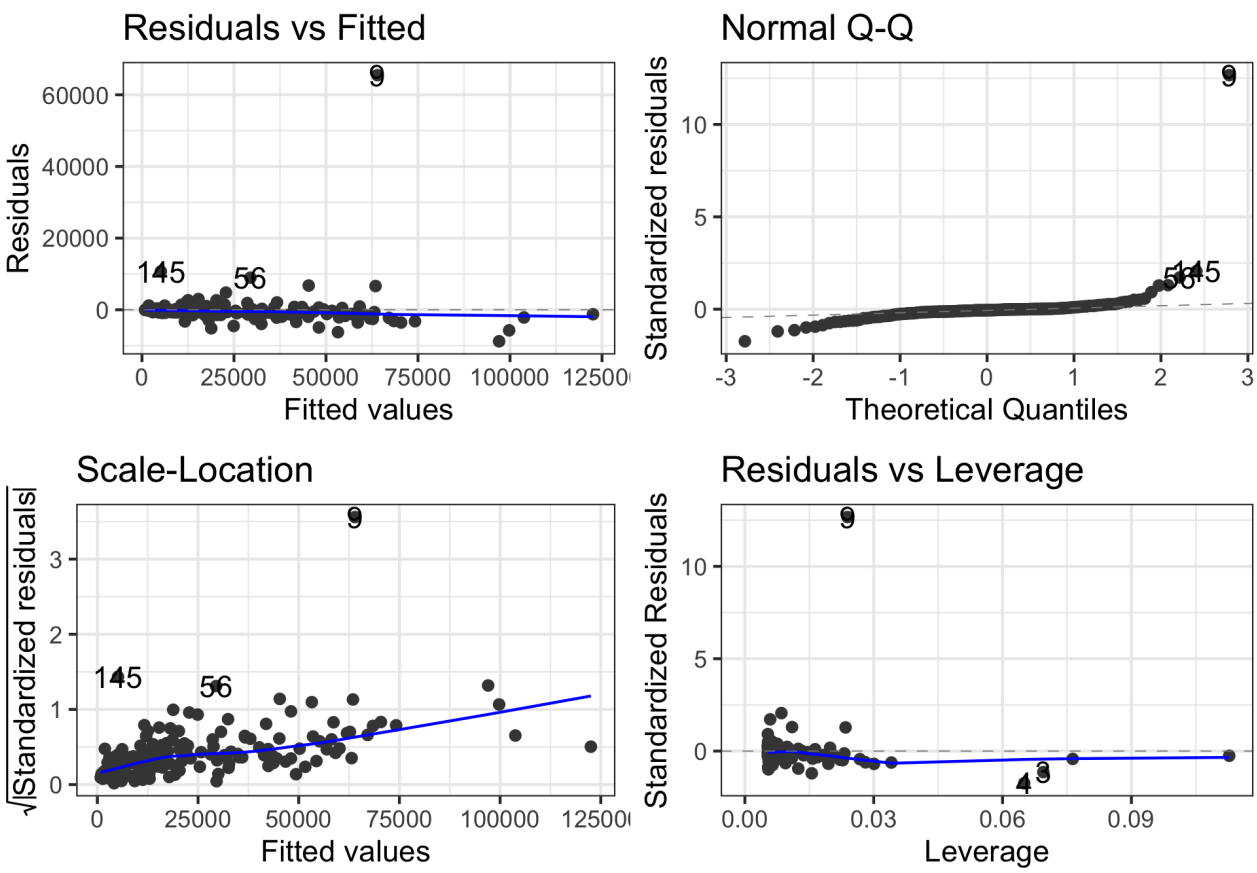


```
ppp_limpo <- ppp[-9, ]

ajuste_limpo <- lm(ppp_wb ~ ppp_fmi,
                   data = ppp_limpo)

summary(ajuste_limpo)
```

```
##
## Call:
## lm(formula = ppp_wb ~ ppp_fmi, data = ppp_limpo)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -6203.6  -581.5  -266.8   283.6 10557.0
```

```
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 289.63575  197.48368   1.467    0.144
## ppp_fmi       1.05339    0.00684 154.005   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1908 on 184 degrees of freedom
## Multiple R-squared:  0.9923, Adjusted R-squared:  0.9923
## F-statistic: 2.372e+04 on 1 and 184 DF,  p-value: < 2.2e-16
```

```
autoplot(ajuste_limpo)
```

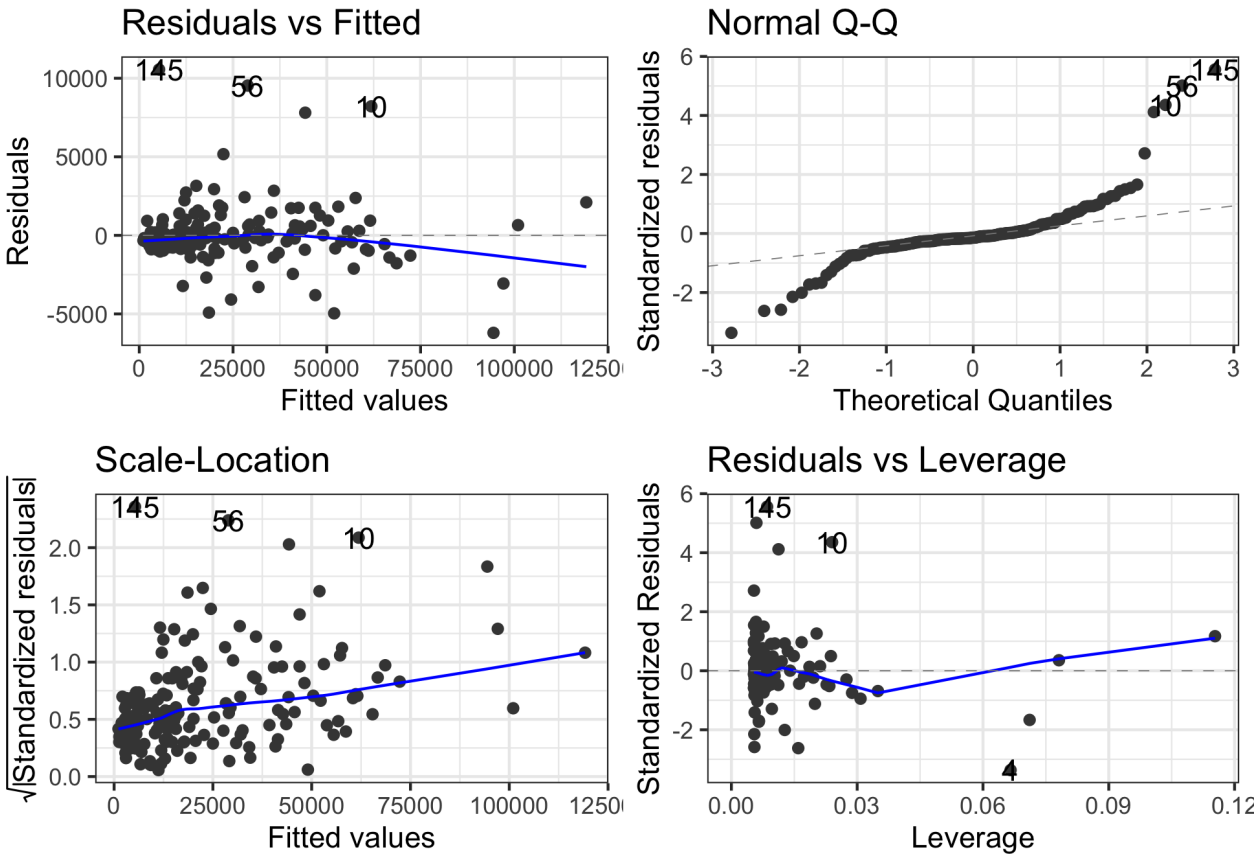

Esse ajuste apresenta diversos problemas. Não há homocedasticidade nos resíduos, como podemos ver no gráfico Residuals vs Fitted. Além disso, os resíduos não apresentam normalidade, fato evidenciado pelo gráfico Normal Q-Q. Por fim, percebemos muitos outliser no gráfico Scale-Location, além de uma forte tendência.